

# Hoja 6 de problemas y prácticas con R

Estadística Computacional I. Grado en Estadística Departamento de Estadística e Investigación Operativa

Marta Venegas Pardo

## Ejercicio 1

1. Responder a los siguientes apartados:

```
library(randtoolbox)
```

```
## Loading required package: rngWELL
```

```
## This is randtoolbox. For an overview, type 'help("randtoolbox")'.
```

Tiene muchas funciones relacionadas con el tema.

**Generar secuencias de tamaño 500 según los generadores de Mersenne-Twister, Congruencia lineal, “Knuth-TAOCP-2002” y una secuencia determinista.**

**Generar de congruencia lineal y algunos contrastes**

```
library(tseries) # Para contrastes de independencia
```

```
## Registered S3 method overwritten by 'quantmod':
```

```
##   method          from
```

```
## as.zoo.data.frame zoo
```

```
n<-500
```

```
set.seed(1)
```

```
(head(xmt<- runif(n) , 10 )) #Mersenne-Twister
```

```
## [1] 0.26550866 0.37212390 0.57285336 0.90820779 0.20168193 0.89838968
```

```
## [7] 0.94467527 0.66079779 0.62911404 0.06178627
```

```
(head(xcl<- congruRand(n),10)) #Generador de congruencia lineal
```

```
## [1] 0.6210185 0.4582407 0.6517764 0.4063970 0.3141388 0.7309768 0.5275602
```

```
## [8] 0.7043181 0.4746586 0.5871574
```

```
(head(xta<-knuthTAOCP(n),10)) #Knuth-TAOCP-2002
```

```
## [1] 0.77559173 0.20262363 0.06309716 0.57894119 0.59421662 0.12908291
```

```
## [7] 0.22554409 0.20561367 0.94868813 0.06787565
```

```
(head(xdet<- ((1:n)-0.5)/n,10))
```


```
## [1] 0.001 0.003 0.005 0.007 0.009 0.011 0.013 0.015 0.017 0.019
```

Dibujar gráficos de líneas e histogramas para las cuatro secuencias.


Gráficos de líneas con plot

```
par(mfrow=c(2,2))
plot(xmt,type="l",main="Mersenne-Twister")
plot(xcl,type="l",main="Congruencia lineal")
plot(xta,type="l",main="Knuth-TAOCP-2002")
plot(xdet,type="l",main="Sec.Determinista")
```


**Mersenne-Twister**




**Congruencia lineal**



**Knuth-TAOCP-2002**

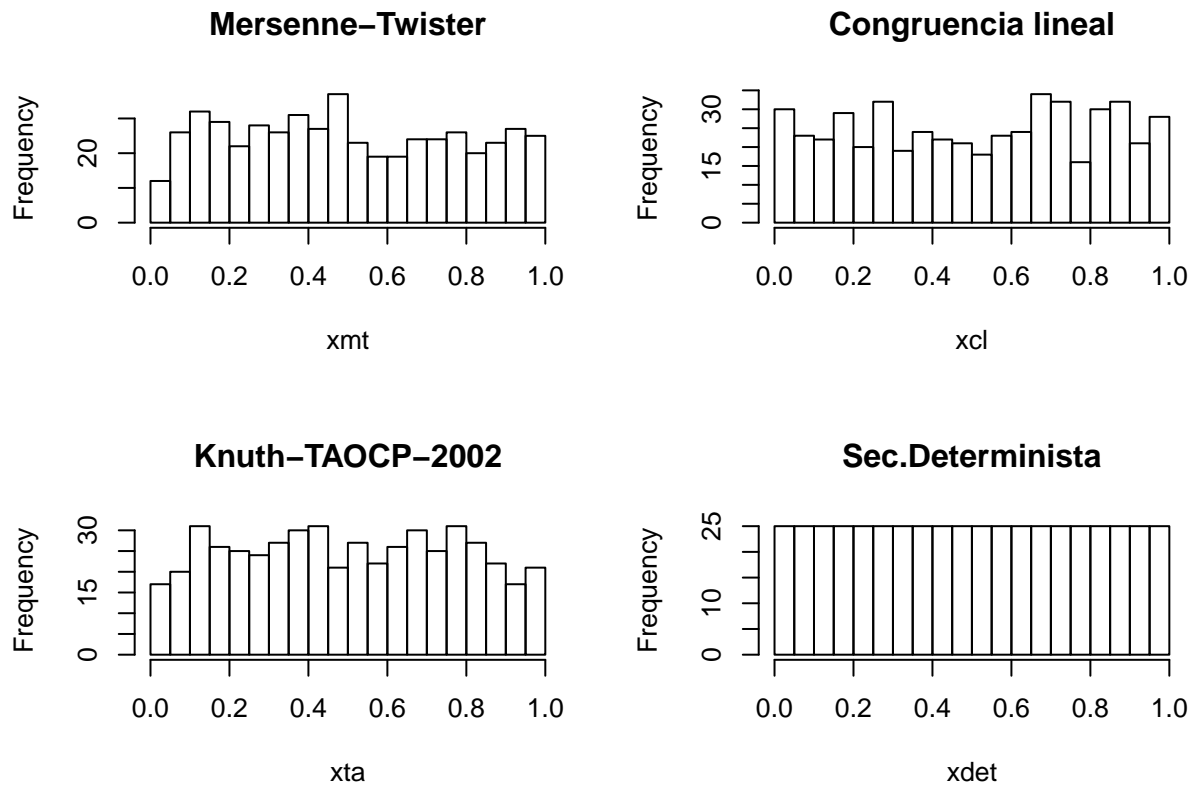


**Sec.Determinista**



Histogramas con hist

```
par(mfrow=c(2,2))
hist(xmt,br=20,main="Mersenne-Twister")
hist(xcl,br=20,main="Congruencia lineal")
hist(xta,br=20,main="Knuth-TAOCP-2002")
hist(xdet,br=20,main="Sec.Determinista")
```



```
par(mfrow=c(1,1))
```

Aplicar contrastes de aleatoriedad sobre las cuatro secuencias.

```
contrastes_aleato<-function(x,titulo) {
  print(titulo)
  ks.test(x, "punif")
  gap.test(x) #Por defecto, l=0, u=0.5
  order.test(x,d=5) #d puede ser 2,3,4,5, pero n debe ser múltiplo de d freq.test(x, 1:4)#Por defecto, se
  serial.test(x,d=5) #n debe ser múltiplo de d (t=2)
  poker.test(x)
  print(runs.test(factor(x>0.5)))
  acf(x,main=titulo)
}
```

Mersenne-Twister

```
contrastes_aleato(xmt,"Mersenne-Twister")


## [1] "Mersenne-Twister"
##
##          Gap test
##
## chisq stat = 16, df = 9, p-value = 0.064
##
## (sample size : 500)
##
## length   observed freq      theoretical freq
```

```

## 1          48          62
## 2          37          31
## 3          16          16
## 4          11          7.8
## 5           5          3.9
## 6           2           2
## 7           0          0.98
## 8           0          0.49
## 9           1          0.24
## 10          1          0.12
##
##          Order test
##
## chisq stat = 121, df = 119, p-value = 0.44
##
##          (sample size : 500)
##
## observed number 0 1 0 0 2 1 1 1 0 1 3 2 2 0 0 2 2 3 0 1 1 0 0 0 0 3 0 0 1 2 1 1 0 0 1 2 0 0 0 1 1
## expected number 0.83
##
##          Serial test
##
## chisq stat = 33, df = 24, p-value = 0.1
##
##          (sample size : 500)
##
## observed number 9 7 7 5 9 12 8 11 12 16 9 11 17 5 14 19 12 7 9 7 13 10 8 8 5
## expected number 10
##
##          Poker test
##
## chisq stat = 3.3, df = 4, p-value = 0.5
##
##          (sample size : 500)
##
## observed number 0 6 56 35 3
## expected number 0.16 9.6 48 38 3.8
##
## Runs Test
##
## data: factor(x > 0.5)
## Standard Normal = -0.8, p-value = 0.4
## alternative hypothesis: two.sided

```

## Mersenne-Twister



No se sale mucho de las líneas, para entender las autocorreaciones.

### Congruencia lineal

```
contrastes_aleato(xmt,"Congruencia Lineal")
```


```
## [1] "Congruencia Lineal"
##
##      Gap test
##
## chisq stat = 16, df = 9, p-value = 0.064
##
##      (sample size : 500)
##
## length  observed freq      theoretical freq
## 1         48           62
## 2         37           31
## 3         16           16
## 4         11           7.8
## 5          5           3.9
## 6          2            2
## 7          0           0.98
## 8          0           0.49
## 9          1           0.24
## 10         1           0.12
##
##      Order test
##
## chisq stat = 121, df = 119, p-value = 0.44
```

```

##
##      (sample size : 500)
##
## observed number  0 1 0 0 2 1 1 1 0 1 3 2 2 0 0 2 2 3 0 1 1 0 0 0 0 3 0 0 1 2 1 1 0 0 1 2 0 0 0 1 1
## expected number  0.83
##
##      Serial test
##
## chisq stat = 33, df = 24, p-value = 0.1
##
##      (sample size : 500)
##
## observed number  9 7 7 5 9 12 8 11 12 16 9 11 17 5 14 19 12 7 9 7 13 10 8 8 5
## expected number  10
##
##      Poker test
##
## chisq stat = 3.3, df = 4, p-value = 0.5
##
##      (sample size : 500)
##
## observed number  0 6 56 35 3
## expected number  0.16 9.6 48 38 3.8
##
## Runs Test
##
## data:  factor(x > 0.5)
## Standard Normal = -0.8, p-value = 0.4
## alternative hypothesis: two.sided

```

## Congruencia Lineal



Los p-valores no están tan al límite como alguno de los anteriores.


### Knuth-TAOCP-2002

```
contrastes_aleato(xta,"Knuth-TAOCP-2002")
```

```
## [1] "Knuth-TAOCP-2002"
##
##          Gap test
##
## chisq stat = 2.9, df = 9, p-value = 0.97
##
##      (sample size : 500)
##
## length  observed freq      theoretical freq
## 1         61          62
## 2         29          31
## 3         20          16
## 4          7         7.8
## 5          4         3.9
## 6          3          2
## 7          1         0.98
## 8          0         0.49
## 9          0         0.24
## 10         0         0.12
##
##          Order test
##
## chisq stat = 123, df = 119, p-value = 0.38
##
##      (sample size : 500)
##
## observed number 1 0 0 0 1 0 2 1 0 2 0 2 1 1 1 1 2 2 0 0 0 1 0 0 0 1 1 0 1 0 2 2 0 0 0 1 1 3 1 0 0
## expected number 0.83
##
##          Serial test
##
## chisq stat = 28, df = 24, p-value = 0.26
##
##      (sample size : 500)
##
## observed number 4 9 9 17 8 14 12 11 11 8 12 15 6 14 7 9 5 12 11 6 8 9 9 16 8
## expected number 10
##
##          Poker test
##
## chisq stat = 2.3, df = 4, p-value = 0.68
##
##      (sample size : 500)
##
## observed number 0 7 48 43 2
## expected number 0.16 9.6 48 38 3.8
##
## Runs Test
```

```
##
## data: factor(x > 0.5)
## Standard Normal = 0.001, p-value = 1
## alternative hypothesis: two.sided
```

## Knuth-TAOCP-2002



## Determinista

```
contrastes_aleato(xdet,"Determinista")
```

```
## [1] "Determinista"
##
##          Gap test
##
## chisq stat = 1.4e+73, df = 249, p-value = 0
##
##      (sample size : 500)
##
## length  observed freq      theoretical freq
## 1         0          62
## 2         0          31
## 3         0          16
## 4         0           7.8
## 5         0           3.9
## 6         0           2
## 7         0           0.98
## 8         0           0.49
## 9         0           0.24
## 10        0           0.12
## 11        0           0.061
```



## 12	0	0.031
## 13	0	0.015
## 14	0	0.0076
## 15	0	0.0038
## 16	0	0.0019
## 17	0	0.00095
## 18	0	0.00048
## 19	0	0.00024
## 20	0	0.00012
## 21	0	6e-05
## 22	0	3e-05
## 23	0	1.5e-05
## 24	0	7.5e-06
## 25	0	3.7e-06
## 26	0	1.9e-06
## 27	0	9.3e-07
## 28	0	4.7e-07
## 29	0	2.3e-07
## 30	0	1.2e-07
## 31	0	5.8e-08
## 32	0	2.9e-08
## 33	0	1.5e-08
## 34	0	7.3e-09
## 35	0	3.6e-09
## 36	0	1.8e-09
## 37	0	9.1e-10
## 38	0	4.5e-10
## 39	0	2.3e-10
## 40	0	1.1e-10
## 41	0	5.7e-11
## 42	0	2.8e-11
## 43	0	1.4e-11
## 44	0	7.1e-12
## 45	0	3.6e-12
## 46	0	1.8e-12
## 47	0	8.9e-13
## 48	0	4.4e-13
## 49	0	2.2e-13
## 50	0	1.1e-13
## 51	0	5.6e-14
## 52	0	2.8e-14
## 53	0	1.4e-14
## 54	0	6.9e-15
## 55	0	3.5e-15
## 56	0	1.7e-15
## 57	0	8.7e-16
## 58	0	4.3e-16
## 59	0	2.2e-16
## 60	0	1.1e-16
## 61	0	5.4e-17
## 62	0	2.7e-17
## 63	0	1.4e-17
## 64	0	6.8e-18
## 65	0	3.4e-18

## 66	0	1.7e-18
## 67	0	8.5e-19
## 68	0	4.2e-19
## 69	0	2.1e-19
## 70	0	1.1e-19
## 71	0	5.3e-20
## 72	0	2.6e-20
## 73	0	1.3e-20
## 74	0	6.6e-21
## 75	0	3.3e-21
## 76	0	1.7e-21
## 77	0	8.3e-22
## 78	0	4.1e-22
## 79	0	2.1e-22
## 80	0	1e-22
## 81	0	5.2e-23
## 82	0	2.6e-23
## 83	0	1.3e-23
## 84	0	6.5e-24
## 85	0	3.2e-24
## 86	0	1.6e-24
## 87	0	8.1e-25
## 88	0	4e-25
## 89	0	2e-25
## 90	0	1e-25
## 91	0	5e-26
## 92	0	2.5e-26
## 93	0	1.3e-26
## 94	0	6.3e-27
## 95	0	3.2e-27
## 96	0	1.6e-27
## 97	0	7.9e-28
## 98	0	3.9e-28
## 99	0	2e-28
## 100	0	9.9e-29
## 101	0	4.9e-29
## 102	0	2.5e-29
## 103	0	1.2e-29
## 104	0	6.2e-30
## 105	0	3.1e-30
## 106	0	1.5e-30
## 107	0	7.7e-31
## 108	0	3.9e-31
## 109	0	1.9e-31
## 110	0	9.6e-32
## 111	0	4.8e-32
## 112	0	2.4e-32
## 113	0	1.2e-32
## 114	0	6e-33
## 115	0	3e-33
## 116	0	1.5e-33
## 117	0	7.5e-34
## 118	0	3.8e-34
## 119	0	1.9e-34


## 120	0	9.4e-35
## 121	0	4.7e-35
## 122	0	2.4e-35
## 123	0	1.2e-35
## 124	0	5.9e-36
## 125	0	2.9e-36
## 126	0	1.5e-36
## 127	0	7.3e-37
## 128	0	3.7e-37
## 129	0	1.8e-37
## 130	0	9.2e-38
## 131	0	4.6e-38
## 132	0	2.3e-38
## 133	0	1.1e-38
## 134	0	5.7e-39
## 135	0	2.9e-39
## 136	0	1.4e-39
## 137	0	7.2e-40
## 138	0	3.6e-40
## 139	0	1.8e-40
## 140	0	9e-41
## 141	0	4.5e-41
## 142	0	2.2e-41
## 143	0	1.1e-41
## 144	0	5.6e-42
## 145	0	2.8e-42
## 146	0	1.4e-42
## 147	0	7e-43
## 148	0	3.5e-43
## 149	0	1.8e-43
## 150	0	8.8e-44
## 151	0	4.4e-44
## 152	0	2.2e-44
## 153	0	1.1e-44
## 154	0	5.5e-45
## 155	0	2.7e-45
## 156	0	1.4e-45
## 157	0	6.8e-46
## 158	0	3.4e-46
## 159	0	1.7e-46
## 160	0	8.6e-47
## 161	0	4.3e-47
## 162	0	2.1e-47
## 163	0	1.1e-47
## 164	0	5.3e-48
## 165	0	2.7e-48
## 166	0	1.3e-48
## 167	0	6.7e-49
## 168	0	3.3e-49
## 169	0	1.7e-49
## 170	0	8.4e-50
## 171	0	4.2e-50
## 172	0	2.1e-50
## 173	0	1e-50

## 174	0	5.2e-51
## 175	0	2.6e-51
## 176	0	1.3e-51
## 177	0	6.5e-52
## 178	0	3.3e-52
## 179	0	1.6e-52
## 180	0	8.2e-53
## 181	0	4.1e-53
## 182	0	2e-53
## 183	0	1e-53
## 184	0	5.1e-54
## 185	0	2.5e-54
## 186	0	1.3e-54
## 187	0	6.4e-55
## 188	0	3.2e-55
## 189	0	1.6e-55
## 190	0	8e-56
## 191	0	4e-56
## 192	0	2e-56
## 193	0	1e-56
## 194	0	5e-57
## 195	0	2.5e-57
## 196	0	1.2e-57
## 197	0	6.2e-58
## 198	0	3.1e-58
## 199	0	1.6e-58
## 200	0	7.8e-59
## 201	0	3.9e-59
## 202	0	1.9e-59
## 203	0	9.7e-60
## 204	0	4.9e-60
## 205	0	2.4e-60
## 206	0	1.2e-60
## 207	0	6.1e-61
## 208	0	3e-61
## 209	0	1.5e-61
## 210	0	7.6e-62
## 211	0	3.8e-62
## 212	0	1.9e-62
## 213	0	9.5e-63
## 214	0	4.7e-63
## 215	0	2.4e-63
## 216	0	1.2e-63
## 217	0	5.9e-64
## 218	0	3e-64
## 219	0	1.5e-64
## 220	0	7.4e-65
## 221	0	3.7e-65
## 222	0	1.9e-65
## 223	0	9.3e-66
## 224	0	4.6e-66
## 225	0	2.3e-66
## 226	0	1.2e-66
## 227	0	5.8e-67

[illegible]

```
## Standard Normal = -22, p-value <2e-16
## alternative hypothesis: two.sided
```

## Determinista



### Test con generadores (no secuencias)

Le pasamos la función generadora y hará un estudio.

```
coll.test(runif,2^7,2^10)
```

```
##
##          Collision test
##
## chisq stat = 0.008, df = 1, p-value = 0.93
##
## Poisson approximation (sample number : 1000 / sample size : 128 / cell number : 1e+06)
##
## collision      observed      expected
## number        count        count
##      0          992          992
##      1           8           7.8
```

p-valor alto, no rechazo.

```
#m=2^10 secuencias de tamaño n=2^7
##por defecto tdim=2
coll.test(congruRand,2^7,2^10)
```

```
##
##          Collision test
##
## chisq stat = 0.4, df = 1, p-value = 0.53
```

```
##
## Poisson approximation (sample number : 1000 / sample size : 128 / cell number : 1e+06)
##
## collision      observed      expected
## number        count        count
##      0         994         992
##      1          6          7.8

coll.test(knuthTAOCP,2^7,2^10)

##
##      Collision test
##
## chisq stat = 0.66, df = 1, p-value = 0.42
##
## Poisson approximation (sample number : 1000 / sample size : 128 / cell number : 1e+06)
##
## collision      observed      expected
## number        count        count
##      0         990         992
##      1         10         7.8
```

## Ejercicio 2

Comparar empíricamente los rendimientos de los siguientes generadores de números aleatorios en (0,1), Mersenne-Twister, Congruencia Lineal, K2nuth-TAOCP-2002,2 además de un generador de números determinista, según los resultados del test de Kolmogorov-Smirnov y el test de huecos.

Utilizar 1000 muestras de tamaño 100 y analizar de forma numérica y gráfica los resultados.

```
library(randtoolbox)
M<-1000
n<-100
pvaloresKS<- matrix(NA,M,4)
pvaloresGap<- matrix(NA,M,4)
colnames(pvaloresKS)<- c("Mersenne-Twister","Congruencia Lineal", "Knuth-TAOCP-2002","Determinista")
colnames(pvaloresGap)<- c("Mersenne-Twister","Congruencia Lineal", "Knuth-TAOCP-2002","Determinista")

for (i in 1:M) {
  if (i%%50==0) {
    cat("Muestra ",i,"de ",M,"\n")
  }
  xmt<- runif(n) #Mersenne-Twister
  xcl<- congruRand(n) #Generador de congruencia lineal
  xta<-knuthTAOCP(n) #Knuth-TAOCP-2002
  xdet<- ((1:n)-0.5)/n #Secuencia determinista
  pvaloresKS[i,]<- c(ks.test(xmt, "punif")$p.value,
                    ks.test(xcl, "punif")$p.value,
                    ks.test(xta, "punif")$p.value,
                    ks.test(xdet, "punif")$p.value)
  pvaloresGap[i,]<- c(gap.test(xmt,echo=FALSE)$p.value,
                    gap.test(xcl,echo=FALSE)$p.value,
                    gap.test(xta,echo=FALSE)$p.value,
                    gap.test(xdet,echo=FALSE)$p.value)
}
```

```
## Muestra 50 de 1000
## Muestra 100 de 1000
## Muestra 150 de 1000
## Muestra 200 de 1000
## Muestra 250 de 1000
## Muestra 300 de 1000
## Muestra 350 de 1000
## Muestra 400 de 1000
## Muestra 450 de 1000
## Muestra 500 de 1000
## Muestra 550 de 1000
## Muestra 600 de 1000
## Muestra 650 de 1000
## Muestra 700 de 1000
## Muestra 750 de 1000
## Muestra 800 de 1000
## Muestra 850 de 1000
## Muestra 900 de 1000
## Muestra 950 de 1000
## Muestra 1000 de 1000
```

```
head(pvaloresKS,10)
```

```
##      Mersenne-Twister Congruencia Lineal Knuth-TAOCP-2002 Determinista
## [1,]      0.442      0.47      0.76      1
## [2,]      0.840      0.90      0.78      1
## [3,]      0.519      0.21      0.99      1
## [4,]      0.715      0.48      0.88      1
## [5,]      0.466      0.12      0.38      1
## [6,]      0.035      0.28      0.74      1
## [7,]      0.933      0.34      0.94      1
## [8,]      0.530      0.69      0.57      1
## [9,]      0.954      0.23      0.41      1
## [10,]     0.976      0.75      0.22      1
```

```
head(pvaloresGap,10)
```

```
##      Mersenne-Twister Congruencia Lineal Knuth-TAOCP-2002 Determinista
## [1,]      6.9e-01      6.8e-01      5.4e-02      0
## [2,]      3.3e-01      5.3e-01      2.6e-02      0
## [3,]      8.3e-01      5.3e-01      4.4e-01      0
## [4,]      2.0e-01      4.8e-01      6.4e-01      0
## [5,]      7.4e-01      6.7e-02      1.5e-01      0
## [6,]      6.0e-01      9.2e-01      7.3e-03      0
## [7,]      5.8e-02      5.8e-01      8.0e-01      0
## [8,]      3.6e-01      3.0e-01      1.7e-13      0
## [9,]      5.0e-01      8.0e-02      4.7e-01      0
## [10,]     4.1e-06      1.8e-06      8.5e-01      0
```

*#Ejercicio: dibujar en una sola pantalla los M p-valores KS y Gap para los #cuatro generadores*

```
par(mfrow=c(2,2))
for (i in 1:4)
{
plot(pvaloresKS[,i],type="l",
     main=colnames(pvaloresKS)[i],
```




```


xlab="Muestra",ylab="p-valor",
col="red",lwd=2,ylim=c(0,1))
lines(pvaloresGap[,i], col="blue",lwd=2)
}
legend("center",col=c("red","blue"),lty=1,
lwd=2,legend=c("KS","Gap"))

```


**Mersenne-Twister**




**Congruencia Lineal**



**Knuth-TAOCP-2002**



**Determinista**



```

par(mfrow=c(1,1))

```

Estimar  $P[p < \alpha]$

```

alfa<- 0.05
rendim<- matrix(NA,4,2)
colnames(rendim)<- c("KS","Gap")
rownames(rendim)<- c("Mersenne-Twister","Congruencia Lineal", "Knuth-TAOCP-2002","Determinista")
for (i in 1:4)
rendim[i,]<-c(mean(pvaloresKS[,i]<=alfa),
              mean(pvaloresGap[,i]<=alfa))
#Ejercicio: completar
rendim

```

```

##           KS  Gap
## Mersenne-Twister 0.044 0.16
## Congruencia Lineal 0.048 0.18
## Knuth-TAOCP-2002 0.038 0.16
## Determinista     0.000 1.00

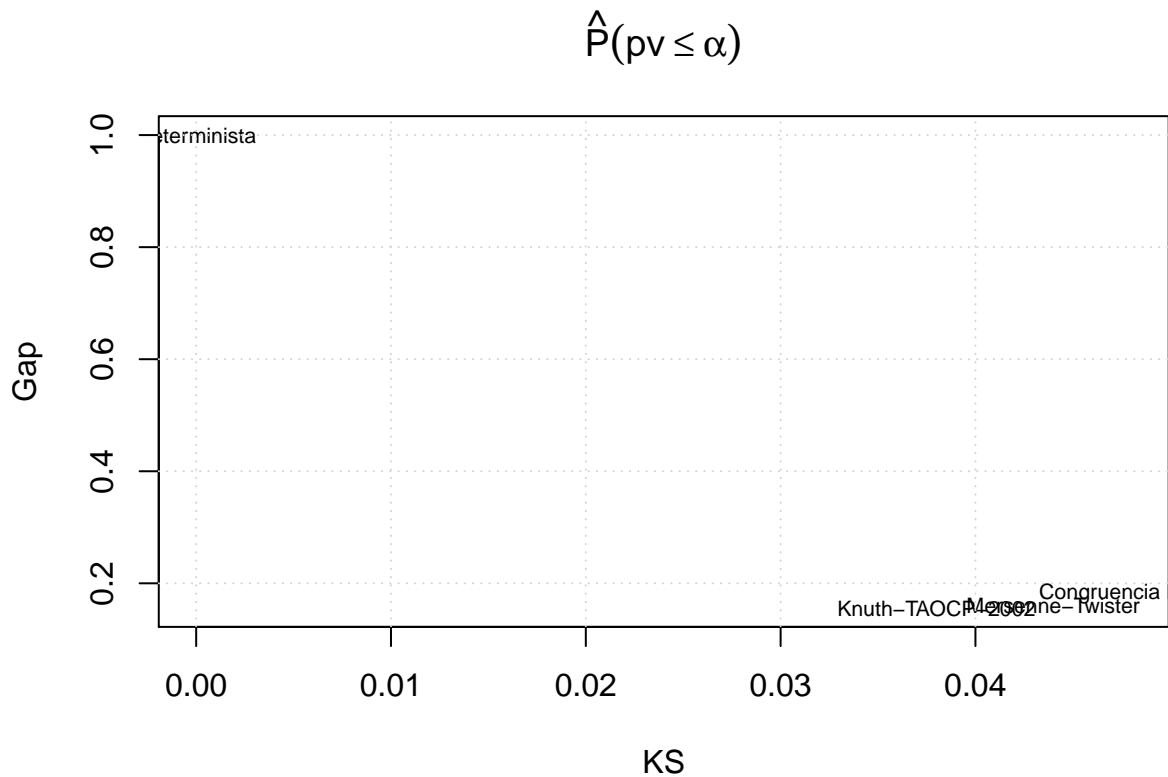
```

```

plot(rendim,type="n",
      main=expression(hat(P)(pv<=alpha)))

```

```
text(rendim,label=rownames(rendim),cex=0.7)
grid()
```



Cuántas veces es mayor un pv que el otro

```
for (i in 1:4)
  cat(colnames(pvaloresKS)[i],mean(pvaloresKS[,i]>pvaloresGap[,i]),"\n")
```

```
## Mersenne-Twister 0.59
## Congruencia Lineal 0.62
## Knuth-TAOCP-2002 0.61
## Determinista 1
```

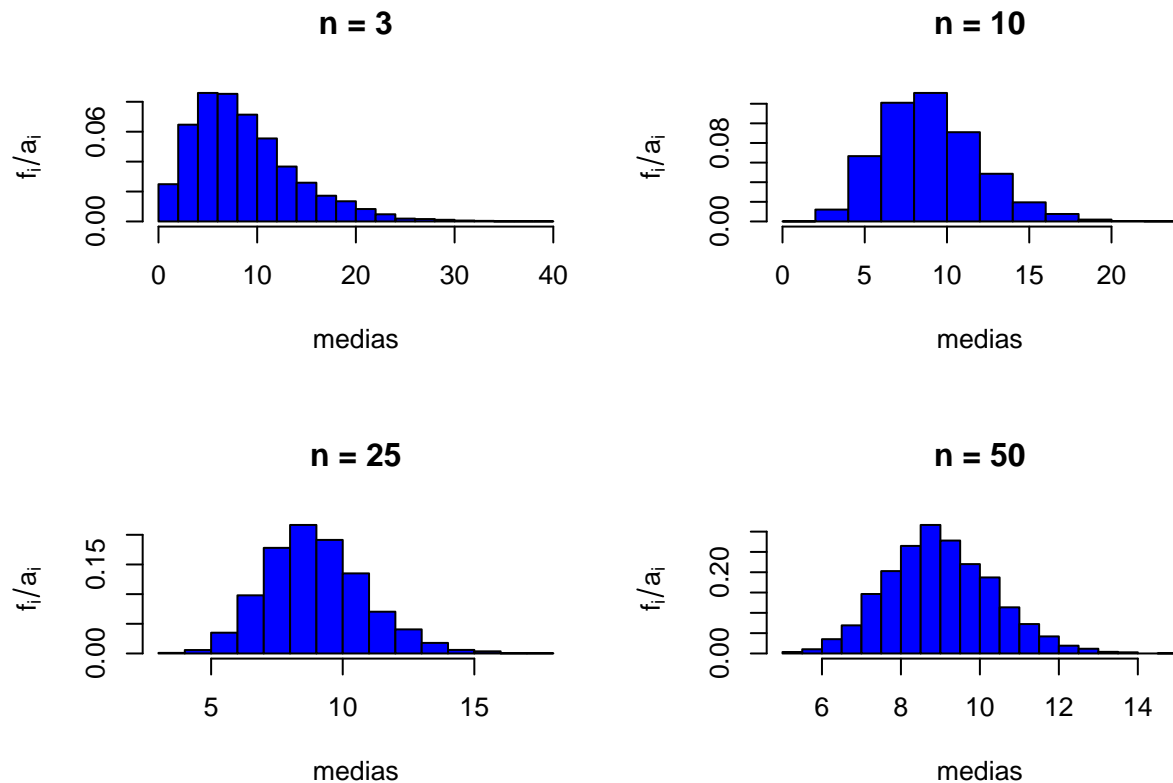
## Ejercicio 3

### Teorema central del límite

3. Ilustrar el Teorema Central del Límite con muestras de una ley Geométrica con parámetro 0.1 para tamaños muestrales 3, 10, 25, 50 y número de muestras 5000.

```
M<-5000 #Núm. de muestras
p<-0.1
vn<-c(3,10,25,50) #Tamaños de cada muestra
paranti<- par(no.readonly=T)
par(mfrow=c(2,2))
for (n in vn) #Ejercicio: completar
{ x<- matrix(rgeom(M*n,p), # Cuantas genero (5000*3), con parametro p=0.1
             nrow=M,ncol=n)
  medias<- rowMeans(x)
```

```
hist(medias,freq=FALSE, col="blue",
     main=paste("n =",n),
     ylab=expression(f[i] /a[i]))
}
```



```
par(paranti)
```

## Ejercicio 4

### Intervalo de confianza con una normal

4. Ilustrar el concepto de intervalo de confianza mediante 100 muestras de tamaño 10 de una ley  $N(0,1)$ , siendo la media poblacional el parámetro de interés.

```
n<-10 #Tamaño muestral
M<-100 #M muestras
alfa<-0.05
media<-0
desvtip<-1
muestras<-matrix(rnorm(M*n,mean=media,sd=desvtip),
                 nrow=M,ncol=n,byrow=TRUE)
```

```
pv<-array(0,M) #M pvalores
exinf<-numeric(M)
exsup<-numeric(M)
```

```
for (i in 1:M)
{ #Ejercicio: completar
  test<-t.test(muestras[i,],conf.level=1-alfa)
```

```

exinf[i]<-test$conf.int[1]
exsup[i]<-test$conf.int[2]
}


```

```

plot(gl(M,n),as.vector(t(muestras)),main=paste("100 I.C. 95% ", "n=",n), xlab="Muestra", ylab="x",col="l",lty=1)
abline(h=media,col="red",lwd=2,lty=2)
lines(exinf,col="darkblue",lwd=4)
lines(exsup,col="darkblue",lwd=4)

```

**100 I.C. 95% n= 10**



```

cat("Cobertura observada =",
100* mean((exinf<= media) & (exsup>=media)), "% \n")

```

```
## Cobertura observada = 97 %
```

```
cat("Longitud media =", mean(exsup-exinf),"\n")
```

```
## Longitud media = 1.4
```

## Ejercicio 5

5. Escribir y probar una función R para generar muestras de una Weibull:

$$f(t) = \lambda \alpha (\lambda t)^{\alpha-1} e^{-(\lambda t)^\alpha}, F(t) = 1 - e^{-(\lambda t)^\alpha}, \lambda, \alpha > 0$$

Generar muestras de tamaño 200 para las configuraciones siguientes, donde:

- $\lambda$  es el parámetro de escala
- $\alpha$  es el parámetro de forma
- $\alpha = 0.5$ ,  $\lambda = 1$

- $\alpha = 1$  ,  $\lambda = 1$
- $\alpha = 2$  ,  $\lambda = 1$
- $\alpha = 2$  ,  $\lambda = 3$


```
generaweib<- function(n,alfa,landa){
  U<- runif(n)
  ((-log(1-U))^(1/alfa))/landa
}
#i)
n<-200
set.seed(129871)
x1<- generaweib(n,0.5,1)
x2<- generaweib(n,1,1)
x3<- generaweib(n,2,1)
x4<- generaweib(n,2,3)
```

## Dibujar los histogramas


```
tit1<-paste("alpha=",0.5,"lambda=",1)
tit2<-paste("alpha=",1,"lambda=",1)
tit3<-paste("alpha=",2,"lambda=",1)
tit4<-paste("alpha=",2,"lambda=",3)

par(mfrow=c(2,2))
hist(x1,main=tit1,br=20,prob=TRUE)
hist(x2,main=tit2,br=20,prob=TRUE)
hist(x3,main=tit3,br=20,prob=TRUE)
hist(x4,main=tit4,br=20,prob=TRUE)
```


**alpha= 0.5 lambda= 1**




**alpha= 1 lambda= 1**



**alpha= 2 lambda= 1**



**alpha= 2 lambda= 3**



```
par(mfrow=c(1,1))
```

## Representar las funciones de distribución empírica y superponer las teóricas

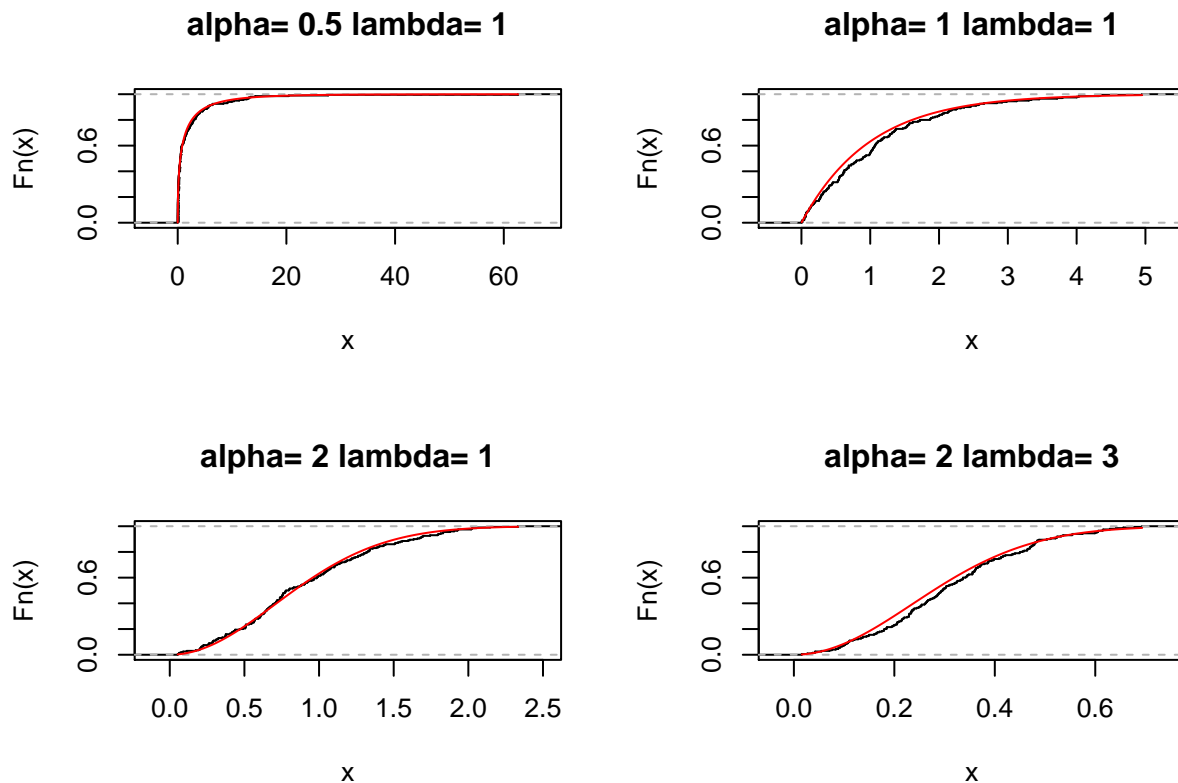
```
par(mfrow=c(2,2))
plot(ecdf(x1),main=tit1,do.points=FALSE,verticals=TRUE)
curve(pweibull(x,0.5,1),min(x1),max(x1),1000,add=TRUE,col="red")

# ecdf: EMpirical cumulative distribution Function

plot(ecdf(x2),main=tit2,do.points=FALSE,verticals=TRUE)
curve(pweibull(x,1,1),min(x2),max(x2),1000,add=TRUE,col="red")

plot(ecdf(x3),main=tit3,do.points=FALSE,verticals=TRUE)
curve(pweibull(x,2,1),min(x3),max(x3),1000,add=TRUE,col="red")

plot(ecdf(x4),main=tit4,do.points=FALSE,verticals=TRUE)
curve(pweibull(x,2,1/3),min(x4),max(x4),1000,add=TRUE,col="red")
```



```
par(mfrow=c(1,1))
```

## Contrastes de bondad de ajuste (fitdistrplus)

SIGUE UNA WEIBULL FRENTE A NO. ESCRIBIR.

Debemos estimar los parámetros por el método de la máxima verosimilitud.

```
library(fitdistrplus)
```

```
print(mv1<-mledist(x1,"weibull"))
```

```
## $estimate
## shape scale
## 0.49 1.07
##
## $convergence
## [1] 0
##
## $value
## [1] 236
##
## $hessian
##      shape scale
## shape 1551  -79
## scale  -79   41
##
## $optim.function
## [1] "optim"
##
## $optim.method
## [1] "Nelder-Mead"
##
## $fix.arg
## NULL
##
## $fix.arg.fun
## NULL
##
## $weights
## NULL
##
## $counts
## function gradient
##      43      NA
##
## $optim.message
## NULL
##
## $loglik
## [1] -236
```

### Test de Kolmogorov-Smirnov de bondad de ajuste

Es el mejor.

```
ks.test(x1,"pweibull",mv1$estimate[1], 1/mv1$estimate[2])
```

```
##
## One-sample Kolmogorov-Smirnov test
##
## data: x1
## D = 0.05, p-value = 0.8
## alternative hypothesis: two-sided
```

```
#R usa 1/landa
```

Cuidado al dar los parámetros.

Conclusión, p-valor mayor que alpha, no tenemos evidencias para negar que la muestra x1 siga una distribución pweibull.

Otra opción: ajustar los datos mediante fitdist y luego aplicar gofstat: Aquí lo que se muestra es el p-valor del test chi-cuadrado de bondad de ajuste.

```
fitweib1 <- fitdist(x1, "weibull")
summary(fitweib1)
```

```
## Fitting of the distribution ' weibull ' by maximum likelihood
## Parameters :
##      estimate Std. Error
## shape      0.49      0.027
## scale      1.07      0.165
## Loglikelihood: -236    AIC:  476    BIC:  483
## Correlation matrix:
##      shape scale
## shape  1.00  0.31
## scale  0.31  1.00
```

Obtenemos los estimadores, que coinciden con los anteriores. También calcula el log de la verosimilitud y calcula los criterios AIC y BIC.

### MEDIANTE el test Chi-Cuadrado

```
gofstat(fitweib1)$chisqpvalue
```

```
## [1] 0.37
```

Acepto  $H_0$ , no encontramos evidencias de que no la sigue.

```
fitweib2 <- fitdist(x2, "weibull")
summary(fitweib2)
```

```
## Fitting of the distribution ' weibull ' by maximum likelihood
## Parameters :
##      estimate Std. Error
## shape      1.1      0.060
## scale      1.1      0.078
## Loglikelihood: -218    AIC:  440    BIC:  447
## Correlation matrix:
##      shape scale
## shape  1.00  0.31
## scale  0.31  1.00
```

```
gofstat(fitweib2)$chisqpvalue
```

```
## [1] 0.25
```

```
fitweib3 <- fitdist(x3, "weibull")
summary(fitweib3)
```

```
## Fitting of the distribution ' weibull ' by maximum likelihood
## Parameters :
##      estimate Std. Error
```



```
## shape      1.9      0.11
## scale      1.0      0.04
## Loglikelihood: -131   AIC:  267   BIC:  273
## Correlation matrix:
##      shape scale
## shape 1.00  0.31
## scale 0.31  1.00
```

```
gofstat(fitweib3)$chisqpvalue
```

```
## [1] 0.32
```

```
fitweib4 <- fitdist(x4, "weibull")
summary(fitweib4)
```

```
## Fitting of the distribution ' weibull ' by maximum likelihood
## Parameters :
##      estimate Std. Error
## shape      2.20      0.124
## scale      0.35      0.012
## Loglikelihood: 103   AIC:  -202   BIC:  -195
## Correlation matrix:
##      shape scale
## shape 1.00  0.31
## scale 0.31  1.00
```

```
gofstat(fitweib4)$chisqpvalue
```

```
## [1] 0.43
```


## Ejercicio 6 “Pesos.RData”

Leer el fichero datos en “Pesos.RData”, y a continuación:

Estimar la densidad por el método del núcleo.

```
load("datos/Pesos.RData")
hist(datos,
      br=30,
      prob=TRUE,
      main="Histograma y estimación de la densidad",
      ylab = expression(hat(f)(x)), xlab="x")
lines(density(datos, bw="SJ"), col="blue", lwd=2) # Estimación por el método del núcleo con density
```


## Histograma y estimación de la densidad



```
## SJ es el método que mejor se porta
```

Vamos a crear una muestra de datos a partir de la función de densidad estimada, serán estimaciones.

```
estimnuc<- density(datos,bw="SJ",n=5000) #Para tener más puntos  
# Devuelve los puntos sobre los que ha hecho las estimaciones  
  
distrib<-data.frame(x=estimnuc$x,  
                    F=cumsum(estimnuc$y)/sum(estimnuc$y))  
# Aquí tenemos una tabla de valores de la función de distribución, no de densidad  
  
plot(distrib,type="l") # Función de distribución
```



Escribir una función para generar valores según dicha densidad estimada.

```
generax<- function(n,distrib) {
  U<-runif(n)
  sapply(U, function(u) min(distrib$x[distrib$F>=u]) ) }
## Mínimo x que supera al valor que busco en la FDD
## Función inversa de la función tabulada
## Sapply: acada elemento del vector que le paso, le aplica la función
generax(10,distrib)
```


```
## [1] 1284 1688 1524 1264 1053 870 1369 1310 1476 1257
```

Simulación de valores:

```
xsimu<- generax(200,distrib)
```

Lo dibujo

```
qqplot(datos,xsimu)
```



```
summary(datos)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      675   1144   1327   1428   1612   3037
```

```
summary(xsimu)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      613   1144   1379   1457   1607   2956
```

Vemos que la mediana con el segundo método es mayor, al igual que la media. Sin embargo, estas evidencias no son significativas para rechazar el test que realizamos a continuación:


**Comparar las distribuciones de una muestra generada de tamaño 200 y el conjunto de datos original.**

```
ks.test(datos,xsimu)
```

```
## Warning in ks.test(datos, xsimu): p-value will be approximate in the presence of
## ties
```

```
##
## Two-sample Kolmogorov-Smirnov test
##
## data:  datos and xsimu
## D = 0.08, p-value = 0.3
## alternative hypothesis: two-sided
```

```
plot(ecdf(datos),main="",do.points=FALSE, verticals=TRUE,col="red")
lines(ecdf(xsimu),do.points=FALSE, verticals=TRUE,col="blue")
```



Aquí vemos porque K-S no rechaza.

## Ejercicio 7

7. Diseñar una función para generar realizaciones de una ley Geométrica simulando el proceso de conteo del número de fracasos antes del primer éxito en la repetición de ensayos Bernoulli. Probar la función y analizar los resultados.


```
#para generar muestra de tamaño n de Ge(p)
#
Geom<- function(n,p) {
  #Inicializaciones
  X<- integer(n)
  #algoritmo
  for (i in 1:n) {
    s<- -1
    repeat
    {
      s<- s+1
      U<- runif(1)
      if (U <= p) break
    }
    X[i]<- s
  }
  X
}
```

```
p<- 0.3
n<- 2000
set.seed(12345)
x<- Geom(n,p)
(tabla<-table(x))
```

```
## x
## 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 17 18 19 21 27
## 598 407 300 198 152 113 63 57 44 25 13 8 6 7 4 1 1 1 1 1

vx<- 1:max(x)
plot(prop.table(tabla),
     type="h",
     ylab="",
     main=paste("p=",p,"n=",n))
lines(vx,dgeom(vx,p),type="h",col="red",lty=2)
legend("topright",
      lty=1:2,
      col=c("black","red"),
      legend=c("Frec.relativa","Prob.Geom"))
grid()
```

**p= 0.3 n= 2000**




No poner valores de p muy pequeños.

```
plot(ecdf(x),
     do.points=FALSE,
     verticals=TRUE,
     ylab="",
     main=paste("p=",p,"n=",n))

curve(pgeom(x,p),
      add=TRUE,
      col="red",
      lty=2)
legend("center",
      lty=1:2,
      col=c("black","red"),
```

```
legend=expression(F[n](x),F[Geom](x))  
grid()
```

**p= 0.3 n= 2000**



Fin hoja